

TOULOUSE SCHOOL OF ECONOMICS

Modélisation Probabiliste et Inférence Variationnelle

Étude Fondamentale des Auto-Encodeurs Variationnels (VAE)

*Application au calcul de la Value-at-Risk (VaR) d'un portefeuille d'actifs à partir de scénarios
de marché synthétiques générés par l'architecture VAE.*

Auteur :

**Bouvier Félix,
Rivallan Mathis**

Toulouse School of Economics

Magistère Économiste Statisticien 2A

Année universitaire 2025/2026

Introduction et Contexte

L’objectif de ce travail est d’étudier les Auto-Encodeurs Variationnels (VAE), introduits par Kingma et Welling en 2013 [1]. Le VAE s’est imposé comme l’un des piliers des modèles génératifs profonds. Contrairement aux approches purement discriminantes, le VAE apprend à modéliser la distribution sous-jacente des données $P(X)$, ce qui lui confère une utilité multidimensionnelle :

- **Réduction de dimension non-linéaire** : Compression de l’information dans un espace latent de faible dimension.
- **Synthèse de données** : Capacité à générer de nouveaux échantillons réalistes en échantillonnant dans l’espace latent.
- **Génération de scénarios et Modélisation du risque (VaR)** : En cartographiant une distribution continue à travers une fonction lisse, le modèle peut capturer des dépendances complexes entre les variables. Dans notre contexte financier, cela permet d’échantillonner massivement l’espace latent pour simuler des scénarios de marché inédits, fournissant ainsi une base empirique pour le calcul de la Value-at-Risk (VaR).

Nous nous plaçons dans un contexte de données tabulaires $x \in \mathbb{R}^d$. Nous supposons l’existence d’une variable latente non observée $z \in \mathbb{R}^k$ responsable de la génération de x . Historiquement, l’estimation de la distribution *a posteriori* de ces variables latentes reposait sur des méthodes d’échantillonnage de type MCMC (Markov Chain Monte Carlo). Bien qu’asymptotiquement exactes, les méthodes MCMC requièrent d’évaluer l’ensemble du jeu de données de manière itérative, ce qui les rend inadaptées aux données massives [2]. Le VAE s’écarte de cette tradition en utilisant l’Inférence Variationnelle (VI). Le problème d’échantillonnage est reformulé en un problème d’optimisation, ce qui permet de sacrifier l’exactitude asymptotique au profit d’une rapidité et d’une scalabilité sans précédent, parfaitement compatibles avec la descente de gradient stochastique.

Organisation du travail

Ce rapport est structuré de manière à concilier la rigueur des démonstrations mathématiques et la compréhension intuitive des mécanismes sous-jacents.

Le corps du texte suit une progression logique allant de l’architecture déterministe (Section 1) vers la formalisation du cadre variationnel (Section 2) et les enjeux de son optimisation pratique (Section 3).

Afin de ne pas briser la linéarité des démonstrations, plusieurs points fondamentaux ont été déportés en annexes :

- Les **prérequis théoriques** concernant l’architecture neurale classique (Annexe A) et les fondements de la théorie de l’information (Annexe B).
- Les **clés d’interprétation** visant à donner une lecture géométrique des projections latentes (Annexe C) ainsi qu’une vision intuitive de la dynamique de l’ELBO (Annexe D).

Cette organisation permet une lecture à deux niveaux : un suivi formel du modèle et un approfondissement conceptuel via les ressources annexes

1 Étude fondamentale des VAE

1.1 De l'Auto-Encodeur Classique au Modèle Variationnel

Avant d'aborder le formalisme bayésien, il est essentiel de comprendre le fonctionnement de l'Auto-Encodeur (AE) déterministe.

1.2 Architecture et Objectif

Un AE classique est composé de deux fonctions paramétrées par des réseaux de neurones :

1. **L'Encodeur** : $z = f_\phi(x)$, qui projette la donnée d'entrée dans un espace latent.
2. **Le Décodeur** : $\hat{x} = g_\theta(z)$, qui tente de reconstruire la donnée initiale à partir de sa représentation compressée.




FIGURE 1 – Architecture générale d'un Auto-Encodeur déterministe. La dimension réduite de l'espace latent ($k \ll d$) force le modèle à apprendre une représentation compressée des données.

1.3 Limitations structurelles

Bien que performant pour la compression, l'AE classique souffre d'un manque de régularité dans son espace latent. Puisque f_ϕ est une fonction déterministe, chaque donnée x est projetée sur un point précis z . Sans contrainte sur la distribution de ces points, l'espace latent est souvent discontinu : deux points proches dans cet espace peuvent correspondre à des reconstructions totalement différentes. Cela rend l'AE classique fondamentalement inapte à la génération de nouvelles données cohérentes et donc incapable de produire des scénarios financiers virtuels fluides.

C'est pour pallier ce manque de structure que nous introduisons l'approche variationnelle, transformant l'AE en un modèle probabiliste. *Une analyse comparative plus approfondie de la géométrie de ces projections (passage du point à la « zone ») est proposée en Annexe C.*

Espace Latent AE (Déterministe) Espace Latent VAE (Stochastique)




FIGURE 2 – Comparaison conceptuelle des espaces latents.

À gauche : L'AE projette les données sur des points précis. L'espace est fragmenté, générer une donnée depuis une zone vide produira un résultat imprévisible.

À droite : Le VAE projette les données sous forme de distributions. La pénalité de Kullback-Leibler [3] force ces distributions à se centrer autour de zéro et à se chevaucher, créant un espace dense, continu et propice à la génération réaliste.

2 Inférence Variationnelle

2.1 Hypothèse des variables latentes et processus génératif

L'objectif fondamental du VAE est de modéliser la distribution réelle des données, notée $p(x)$. Pour ce faire, nous formulons l'hypothèse que les données observées x (souvent complexes et de haute dimension) sont générées par des facteurs sous-jacents non observés z , évoluant dans un espace latent de dimension réduite.

Ce postulat repose sur l'idée que la variabilité de x peut être résumée par des "concepts" simples (ex : dans un jeu de données de visages, z pourrait représenter l'angle de vue ou l'expression). Mathématiquement, la vraisemblance marginale est définie par la formule des probabilités totales :

$$p_{\theta}(x) = \int p_{\theta}(x|z)p(z)dz \quad (1)$$

Dans ce cadre, nous définissons deux composants clés :

- **La loi a priori** $p(z)$: Nous supposons que les variables latentes suivent une distribution simple, généralement une Gaussienne centrée réduite $\mathcal{N}(0, I)$.
- **La vraisemblance** $p_{\theta}(x|z)$: Représentée par le *décodeur*, elle modélise le processus de génération qui transforme un point latent simple en une donnée complexe.

2.2 Le problème de l'intraitabilité

Si notre but est de maximiser $\log p_{\theta}(x)$ pour que notre modèle colle à la réalité, nous nous heurtons à un obstacle majeur : l'intégrale définie ci-dessus est *intraitable*. Il est numériquement impossible de tester toutes les configurations de z pour évaluer la probabilité d'un seul x .

Pour contourner ce problème, nous avons besoin de savoir quels z sont "responsables" de la génération de x . Cela revient à chercher la distribution *a posteriori* $p_\theta(z|x)$ via la règle de Bayes :

$$p_\theta(z|x) = \frac{p_\theta(x|z)p(z)}{p_\theta(x)} \quad (2)$$

Le dénominateur (l'évidence) étant incalculable, nous ne pouvons pas obtenir $p_\theta(z|x)$ de manière exacte. C'est ici qu'intervient l'approche variationnelle : nous introduisons un modèle d'inférence $q_\phi(z|x)$ (l'encodeur) chargé d'approximer ce *posteriori* inconnu.

Définition : Divergence de Kullback-Leibler (KL)

Pour mesurer la proximité entre notre approximation $q_\phi(z|x)$ et le vrai *a posteriori*, nous utilisons la divergence KL :

$$D_{KL}(q_\phi(z|x) \parallel p_\theta(z|x)) = \mathbb{E}_{z \sim q} \left[\log \frac{q_\phi(z|x)}{p_\theta(z|x)} \right] \quad (3)$$

Les fondements théoriques issus de la théorie de l'information (entropie et surprise) sont détaillés en Annexe B.

2.3 Démonstration de l'ELBO

Partons de l'expression de la log-vraisemblance marginale :

$$\log p_\theta(x) = \mathbb{E}_{z \sim q_\phi(z|x)} [\log p_\theta(x)] \quad (4)$$

$$= \mathbb{E}_{q_\phi} \left[\log \frac{p_\theta(x, z)}{p_\theta(z|x)} \right] \quad (\text{par la règle de Bayes}) \quad (5)$$

$$= \mathbb{E}_{q_\phi} \left[\log \frac{p_\theta(x, z)q_\phi(z|x)}{q_\phi(z|x)p_\theta(z|x)} \right] \quad (6)$$

$$= \mathbb{E}_{q_\phi} \left[\log \frac{p_\theta(x, z)}{q_\phi(z|x)} \right] + \mathbb{E}_{q_\phi} \left[\log \frac{q_\phi(z|x)}{p_\theta(z|x)} \right] \quad (7)$$

Nous identifions alors deux termes distincts : l'ELBO et la divergence KL entre l'encodeur et le vrai *a posteriori*.

Équation Fondamentale du VAE

$$\log p_\theta(x) = \mathcal{L}(\theta, \phi; x) + D_{KL}(q_\phi(z|x) \parallel p_\theta(z|x)) \quad (8)$$

Où $\mathcal{L}$ est l'ELBO (Evidence Lower Bound) :

$$\mathcal{L}(\theta, \phi; x) = \mathbb{E}_{z \sim q_\phi(z|x)} [\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x) \parallel p(z)) \quad (9)$$

2.4 De l'égalité à l'inégalité

Puisque $D_{KL}(q_\phi(z|x) \parallel p_\theta(z|x)) \geq 0$, nous en déduisons l'inégalité :

$$\log p_\theta(x) \geq \mathcal{L}(\theta, \phi; x) \quad (10)$$

Maximiser l'ELBO revient donc à maximiser une borne inférieure de la log-vraisemblance, tout en forçant l'encodeur q_ϕ à se rapprocher du vrai *a posteriori* $p_\theta(z|x)$.

L'optimisation conjointe des paramètres θ (décodeur) et ϕ (encodeur) repose sur une dynamique d'équilibre entre reconstruction et régularisation. Pour une interprétation intuitive de cette mécanique (concept du « plancher mobile » et rôle des réseaux de neurones), se reporter à l'Annexe D.

3 Optimisation et l'Astuce de Reparamétrisation

Pour utiliser ce modèle en pratique, nous devons maximiser l'ELBO par rapport aux paramètres θ (le décodeur) et ϕ (l'encodeur) via une descente de gradient stochastique.

3.1 Le blocage de la rétropropagation

Comme détaillé dans l'Annexe A, l'apprentissage de bout en bout des réseaux de neurones repose sur l'algorithme de rétropropagation du gradient (*backpropagation*). Or, le calcul de l'ELBO nécessite d'évaluer l'espérance $\mathbb{E}_{z \sim q_\phi(z|x)}$. En pratique, on approxime cette espérance par échantillonnage de Monte-Carlo.

Le problème mathématique et informatique est le suivant : l'échantillonnage est une opération stochastique, non dérivable. Il est impossible de calculer le gradient $\nabla_\phi z$. La chaîne de dérivation est brisée, ce qui empêche la mise à jour des poids de l'encodeur.

3.2 Démonstration formelle de la reparamétrisation

Pour contourner ce problème, Kingma et Welling (2013) introduisent le *Reparameterization Trick*. L'objectif est de réécrire l'espérance par rapport à $q_\phi(z|x)$ de telle sorte que l'estimateur de Monte-Carlo devienne dérivable par rapport à ϕ .

Soit z une variable aléatoire continue. Sous certaines conditions, il est possible d'exprimer z comme une fonction déterministe $z = g_\phi(\epsilon, x)$, où ϵ est une variable aléatoire auxiliaire dont la distribution marginale $p(\epsilon)$ est indépendante de ϕ .

Par le théorème de transfert (changement de variable), pour toute fonction f , nous avons l'égalité des intégrales :

$$\int q_\phi(z|x) f(z) dz = \int p(\epsilon) f(g_\phi(\epsilon, x)) d\epsilon \quad (11)$$

Cette réécriture est fondamentale : l'espérance $\mathbb{E}_{q_\phi}[f(z)]$ est transformée en $\mathbb{E}_{p(\epsilon)}[f(g_\phi(\epsilon, x))]$. La stochasticité est désormais confinée dans $p(\epsilon)$, tandis que les paramètres ϕ ne sont présents que dans la fonction déterministe g_ϕ .

3.3 Application au cas Gaussien

Dans le cadre de notre modèle, nous supposons que l'encodeur prédit les paramètres d'une loi normale multivariée diagonale : $q_\phi(z|x) = \mathcal{N}(\mu, \sigma^2 I)$.

En appliquant le principe défini ci-dessus, nous choisissons le bruit auxiliaire $\epsilon \sim \mathcal{N}(0, I)$. La transformation déterministe g_ϕ correspond alors à la standardisation inverse (famille *location-scale*) :

L'Astuce de Reparamétrisation (Cas Gaussien)


$$z = \mu + \sigma \odot \epsilon \quad \text{avec} \quad \epsilon \sim \mathcal{N}(0, I) \quad (12)$$

Où $\odot$ désigne le produit d'Hadamard (terme à terme) et où μ, σ sont les sorties de l'encodeur.

3.4 Conséquences pour le graphe de calcul

Grâce à cette transformation, la variable z devient une transformation linéaire déterministe par rapport à μ et σ . La rétropropagation redevient possible : les gradients $\frac{\partial z}{\partial \mu} = 1$ et $\frac{\partial z}{\partial \sigma} = \epsilon$ sont parfaitement bien définis. L'erreur peut traverser z pour atteindre le réseau de neurones de l'encodeur.

Réseau original (Brisé)



Astuce de Reparamétrisation




FIGURE 3 – Graphe de calcul de l'astuce de reparamétrisation. À gauche, le nœud stochastique z bloque la rétropropagation vers ϕ . À droite, le tirage aléatoire est isolé dans ϵ (qui n'a pas de paramètres à apprendre). Le chemin de la perte vers μ et σ est désormais continu et différentiable.

3.5 L'estimateur SGVB et la Fonction de Perte (Loss)

En pratique, l'optimisation par descente de gradient stochastique ne s'effectue pas sur l'ensemble du jeu de données, mais sur des sous-échantillons aléatoires appelés *mini-batches* de taille M .

De plus, l'espérance de l'erreur de reconstruction $\mathbb{E}_{q_\phi}[\log p_\theta(x|z)]$ doit être approximée. Kingma et Welling (2013) proposent l'estimateur SGVB (*Stochastic Gradient Variational Bayes*). Ils démontrent empiriquement que pour un mini-batch suffisamment grand (ex : $M = 100$), il suffit de tirer un seul échantillon latent ($L = 1$) par observation pour que l'estimateur converge.

En Deep Learning, les optimiseurs sont conçus pour minimiser une fonction. Nous définissons donc notre fonction de perte empirique $\mathcal{L}_{SGVB}$ sur un mini-batch comme l'opposé de l'ELBO. En utilisant la formulation analytique de la divergence KL pour des lois normales (détaillée par les auteurs dans leur article), la perte totale pour un point x_i devient :

Fonction de Perte Empirique du VAE

$$\mathcal{L}_{total}(x_i) = \underbrace{-\log p_\theta(x_i|z_i)}_{\text{Erreur de reconstruction}} + \underbrace{D_{KL}(q_\phi(z|x_i) \parallel p(z))}_{\text{Régularisation}} \quad (13)$$

Avec $z_i = \mu_i + \sigma_i \odot \epsilon_i$, tiré avec $\epsilon_i \sim \mathcal{N}(0, I)$.

Pour un espace latent de dimension k , le terme de régularisation a pour solution analytique exacte :

$$D_{KL} = -\frac{1}{2} \sum_{j=1}^k (1 + \log(\sigma_{i,j}^2) - \mu_{i,j}^2 - \exp(\log(\sigma_{i,j}^2))) \quad (14)$$

L'entraînement consiste alors à rétropropager la moyenne de $\mathcal{L}_{total}(x_i)$ sur l'ensemble du mini-batch pour mettre à jour conjointement θ et ϕ .

4 Application : implémentation d'un VAE

Afin de mieux comprendre le fonctionnement du VAE et ses possibles cas d'usage, une application concrète a été réalisée. Bien que l'application la plus connue des VAE soit la génération d'images, il est également possible de les appliquer à bien d'autres contextes, notamment dans le domaine de la finance. Dans ce travail, un VAE a été entraîné sur des données historiques de rendements d'un portefeuille de 60 actifs financiers diversifiés. En tirant des points depuis l'espace latent appris, il est alors possible de construire des scénarios réalistes de rendements du portefeuille. L'objectif final de cette application est de calculer des indicateurs de risque de marché, la Value at Risk (VaR) et l'Expected Shortfall (ES), à partir de ces scénarios générés. Pour cela, l'étude s'appuie sur des données historiques couvrant la période du 18 novembre 2004 au 1^{er} juin 2026. En se basant sur plus de 21 ans de données, le VAE génère de nouveaux scénarios de rendements, dont la fiabilité est ensuite évaluée par un test de backtesting (test de Kupiec) comparant la VaR estimée aux rendements historiques réellement observés.

4.1 Définitions des indicateurs statistiques et de risque

Cette section introduit les principaux indicateurs utilisés dans l'application, tant sur le plan statistique que sur le plan de la mesure du risque financier.

4.1.1 Asymétrie et aplatissement

L'asymétrie (*skewness*) mesure le degré de symétrie d'une distribution autour de sa moyenne. Pour une variable aléatoire X de moyenne μ et d'écart-type σ , elle est définie par :

$$\text{Skewness} = \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right] \quad (15)$$

Une skewness nulle indique une distribution symétrique, une valeur négative traduit une asymétrie à gauche, c'est-à-dire que les pertes extrêmes sont plus probables que des gains de même amplitude.

L'aplatissement (*kurtosis*) mesure le poids des queues de distribution par rapport à une loi normale. Il est défini par :

$$\text{Kurtosis} = \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] \quad (16)$$

Une distribution normale présente une kurtosis égale à 3. En pratique, on utilise souvent l'excès de kurtosis, défini comme la kurtosis moins 3. Une valeur supérieure à 3 indique des queues épaisses (*fat tails*), caractéristique bien documentée des rendements financiers.

4.1.2 Value at Risk

La Value at Risk (VaR) est un indicateur de risque financier. Hull (2012) [4] la définit comme le niveau de perte qui ne sera pas dépassé avec un certain niveau de confiance, sur un horizon temporel donné. Formellement, pour un niveau de confiance $\alpha \in (0, 1)$ et un horizon T , la VaR est définie par :

$$\mathbb{P}(L > \text{VaR}_\alpha) = 1 - \alpha \quad (17)$$

où L désigne la perte du portefeuille. Par exemple, une VaR à 99% signifie qu'il n'y a qu'une probabilité de 1% que la perte dépasse ce seuil sur l'horizon considéré. Dans ce travail, la VaR est calculée aux niveaux de confiance de 95% et 99%.

Toutefois, la VaR présente une limite importante : elle ne renseigne pas sur l'ampleur des pertes au-delà du seuil. Comme le souligne Hull (2012) [4], la VaR répond à la question « jusqu'où peuvent aller les pertes ? » mais ne dit rien sur ce qui se passe dans la queue de distribution.

4.1.3 Conditional Value at Risk

La Conditional Value at Risk (CVaR), également appelée *Expected Shortfall* (ES), pallie cette limite. Hull (2012) [4] la définit comme la perte espérée conditionnellement au fait que celle-ci dépasse la VaR. Formellement :

$$\text{CVaR}_\alpha = \mathbb{E}[L \mid L > \text{VaR}_\alpha] \quad (18)$$

La CVaR répond ainsi à la question « si les pertes dépassent la VaR, quelle est l'ampleur moyenne de ces pertes ? ». Elle est considérée comme une mesure de risque plus complète que la VaR, notamment parce qu'elle est *cohérente* au sens d'Artzner et al. (1999) [5], ce qui signifie qu'elle respecte la propriété de sous-additivité : le risque d'un portefeuille diversifié est toujours inférieur ou égal à la somme des risques individuels.

4.2 Présentation des données

Les données utilisées dans ce travail proviennent du fournisseur de données financières Yahoo Finance. Les prix utilisés sont les prix de fermeture journaliers des actifs.

4.2.1 Composition du portefeuille

Le portefeuille est composé de 60 actifs financiers, sélectionnés afin de représenter une large diversité de classes d’actifs et de zones géographiques : indices boursiers internationaux, ETFs sectoriels et pays, matières premières, obligations et taux d’intérêt, ainsi que le dollar américain. Chaque actif se voit attribuer une pondération égale de 1/60 (soit environ 1,67%), afin de ne pas privilégier une classe d’actifs particulière dans la construction du portefeuille. Le tableau 1 présente la composition par catégorie.

Catégorie	Tickers
Indices boursiers larges	$\wedge$ GSPC, $\wedge$ DJI, $\wedge$ IXIC, $\wedge$ FTSE, $\wedge$ FCHI, $\wedge$ GDAXI, $\wedge$ SSMI, $\wedge$ N225, $\wedge$ HSI, $\wedge$ AEX, $\wedge$ BSESN, $\wedge$ AXJO
ETFs actions US larges	SPY, QQQ, DIA, IWM, IVV, VTI
ETFs actions internationales	EFA, EEM
ETFs sectoriels (US)	XLFX, XLK, XLE, XLY, XLP, XLI, XLB, XLV, XLU, IYR, VOX
ETFs pays	EWJ, EWU, EWG, EWQ, EWC, EWH, EWW, EWA, EWS, FXI
Matières premières	GLD, GC=F, CL=F, NG=F, KC=F, ZC=F, ZW=F, HG=F
Contrats à terme indiciels	ES=F, NQ=F
Obligations et taux	TLT, IEF, SHY, LQD, AGG, TIP, $\wedge$ TNX, $\wedge$ TYX
Change	DX-Y.NYB

TABLE 1 – Composition du portefeuille (60 actifs, pondération égale 1/60)

4.2.2 Calcul des rendements

Les prix de fermeture journaliers sont transformés en rendements logarithmiques, définis pour un actif i à la date t par :

$$r_{i,t} = \ln \left(\frac{P_{i,t}}{P_{i,t-1}} \right) \quad (19)$$

où $P_{i,t}$ désigne le prix de fermeture de l’actif i à la date t . Conformément à la pratique standard en finance quantitative, les rendements logarithmiques sont retenus plutôt que les rendements arithmétiques, notamment pour leur propriété d’additivité temporelle et pour garantir la positivité des prix reconstruits.

4.2.3 Statistiques descriptives

Le tableau 2 présente une synthèse des statistiques descriptives des rendements logarithmiques journaliers des 60 actifs sur l’échantillon disponible (novembre 2004 – juin 2026). Le détail actif par actif est fourni dans le tableau 6 en annexe E.

Sur les 60 actifs, 50 présentent une skewness négative, les pertes extrêmes sont globalement plus fréquentes que des gains de même amplitude. Le NQ=F (future Nasdaq)

Statistique	Moyenne	Médiane	Min	Max
Moyenne journalière	0.0264%	0.0264%	-0.0174%	0.0674%
Écart-type	1.529%	1.471%	0.111%	4.122%
Skewness	-0.310	-0.394	-1.359	2.126
Kurtosis	14.02	10.91	3.00	60.64

TABLE 2 – Synthèse des statistiques descriptives des rendements journaliers, 60 actifs (novembre 2004 – juin 2026)

affiche le meilleur rendement moyen journalier (0.067%), tandis que le NG=F (gaz naturel) possède le pire rendement moyen journalier avec un rendement en négatif (-0.017%) sur la période.

La kurtosis moyenne sur l'échantillon (14.0) confirme la présence généralisée de queues épaisses (fat tails), argument central en faveur du recours à un modèle génératif non paramétrique comme le VAE. Toutefois, un sous-ensemble d'actifs affiche des valeurs de kurtosis nettement supérieures au reste du portefeuille : CL=F (60.6), LQD (57.6), AGG (52.9), $\hat{T}NX$ (41.6) et $\hat{T}YX$ (36.1). Ces valeurs, très supérieures à celles observées sur les indices actions larges (typiquement entre 7 et 15), sont probablement attribuables à un nombre restreint de mouvements extrêmes ponctuels plutôt qu'à une caractéristique structurelle de la distribution. Cette hétérogénéité est à garder à l'esprit : elle signifie que le VAE devra apprendre à représenter des profils de risque très différents selon les classes d'actifs au sein d'un même espace latent partagé.

4.2.4 Matrice de corrélation

La figure 4 présente la matrice de corrélation des rendements journaliers des 60 actifs. On observe une forte redondance entre certains proxys du marché actions américain (par exemple SPY et $\hat{G}SPC$, corrélés à 0.993), une quasi-indépendance de l'or (GLD) vis-à-vis des indices actions (corrélation de 0.080 avec le $\hat{G}SPC$), ainsi qu'une relation négative entre le dollar américain (DX-Y.NYB) et les actions (-0.207 avec le $\hat{G}SPC$). Cette hétérogénéité des dépendances entre classes d'actifs constitue un défi de modélisation pour le VAE.




FIGURE 4 – Matrice de corrélation des rendements logarithmiques journaliers

4.2.5 Évolution des prix

La figure 5 présente l'évolution des 60 actifs du portefeuille normalisés à une base 100, sur la période novembre 2004 – juin 2026. Le grand nombre de séries superposées limitant la lisibilité individuelle du graphique, celui-ci est fourni à titre illustratif de la diversité des trajectoires plutôt que pour une lecture actif par actif détaillée.

4.3 Architecture du VAE

Le VAE implémenté dans cette application est un perceptron multicouche symétrique, dont les dimensions ont été fixées empiriquement. Le vecteur d'entrée $x \in \mathbb{R}^{60}$ correspond

aux rendements journaliers des 60 actifs du portefeuille.

4.3.1 Encodeur

L'encodeur $q_\phi(z|x)$ est composé de deux couches cachées de dimension 128, chacune suivie d'une activation ReLU. Il prédit ensuite les paramètres de la distribution latente via deux couches linéaires parallèles :

$$h = \text{ReLU}(W_2 \cdot \text{ReLU}(W_1 x + b_1) + b_2) \quad (20)$$

$$\mu = W_\mu h + b_\mu \quad (21)$$

$$\log \sigma^2 = W_\sigma h + b_\sigma \quad (22)$$

où $\mu, \log \sigma^2 \in \mathbb{R}^{18}$. Le choix de prédire $\log \sigma^2$ plutôt que σ^2 directement garantit que la variance reste positive pour tout réel prédit par le réseau.

4.3.2 Espace latent

La variable latente est obtenue par le *reparameterization trick* présenté en Section 3 :

$$z = \mu + \sigma \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I_{18}) \quad (23)$$

La dimension latente est fixée à $k = 18$, soit un peu moins du tiers de la dimension d'entrée. Ce choix permet au modèle de capturer des structures complexes non directement observables dans les données brutes, telles que des régimes de marché ou des facteurs de volatilité latents, tout en restant régularisé par la divergence KL qui contraint l'espace latent à rester proche de $\mathcal{N}(0, I_{18})$. Comme le soulignent Arian et al. (2020) dans un contexte similaire de calcul de VaR par VAE, un espace latent plus grand améliore la capacité de reconstruction du modèle [6].

4.3.3 Décodeur

Le décodeur $p_\theta(x|z)$ est symétrique à l'encodeur. Il prend en entrée le vecteur latent $z \in \mathbb{R}^{18}$ et reconstruit le vecteur de rendements via deux couches cachées de dimension 128 suivies d'une couche de sortie linéaire :

$$h' = \text{ReLU}(W_3 z + b_3) \quad (24)$$

$$\hat{x} = W_5 \cdot \text{ReLU}(W_4 h' + b_4) + b_5 \quad (25)$$

L'absence d'activation en sortie est intentionnelle : les rendements logarithmiques peuvent prendre des valeurs positives ou négatives, une activation comme la sigmoïde ou la ReLU biaiserait artificiellement les scénarios générés.

4.3.4 Fonction de perte et Entraînement

Conformément au cadre théorique développé en Section 3, la fonction de perte est la somme de l'erreur de reconstruction et de la divergence KL :

$$\mathcal{L}_{total} = \underbrace{\frac{1}{N} \sum_{i=1}^N \|x_i - \hat{x}_i\|^2}_{\text{MSE (reconstruction)}} + \underbrace{D_{KL}(q_\phi(z|x) \parallel \mathcal{N}(0, I))}_{\text{Régularisation}} \quad (26)$$

Le terme de reconstruction est l’erreur quadratique moyenne (MSE), adapté aux données continues. Le terme de régularisation a pour expression analytique exacte, dérivée en Section 3 :

$$D_{KL} = -\frac{1}{2} \sum_{j=1}^{18} (1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2) \quad (27)$$

Le coefficient $\beta = 1$ devant la divergence KL correspond au VAE standard de Kingma et Welling [1]. L’optimisation des poids du réseau a été réalisée sur 120 époques. La minimisation de la perte s’est faite via l’optimiseur Adam avec un taux d’apprentissage initial de 0.001. De plus, pour garantir la stabilité de l’apprentissage, un écrêtage du gradient (*gradient clipping*) a été appliqué.

4.4 Qualité de la génération des scénarios

4.4.1 Comparaison actif par actif

Afin d’évaluer la capacité du VAE à reproduire la distribution marginale de chaque actif, un test de Kolmogorov-Smirnov à deux échantillons est appliqué entre les rendements historiques et les 10 000 scénarios générés, pour chacun des 60 actifs. L’hypothèse nulle H_0 postule que les deux échantillons sont issus de la même distribution.

Sur les 60 actifs testés, seuls 3 ($\hat{\text{GDAXI}}$, EEM, ES=F) ne permettent pas de rejeter H_0 au seuil de 5%. Pour les 57 autres actifs, l’hypothèse d’égalité des distributions est rejetée, avec des statistiques de test particulièrement élevées pour EWJ (KS = 0.456), SHY (KS = 0.412), $\hat{\text{GSPC}}$ (KS = 0.344), EWG (KS = 0.341) et AGG (KS = 0.329).

Ce résultat doit être interprété avec prudence plutôt que comme un échec pur et simple du modèle. Le test de Kolmogorov-Smirnov standard est en effet particulièrement sensible aux écarts situés au centre de la distribution, et relativement peu puissant pour détecter des différences spécifiquement localisées dans les queues, une limite montrée par Chicheportiche et Bouchaud (2012) [7]. Une limite d’autant plus pertinente ici que, comme le montre la section suivante, l’écart principal entre scénarios générés et rendements historiques concerne précisément le comportement des queues plutôt que le corps de la distribution. Les actifs affichant les écarts les plus marqués renvoient en réalité à deux profils distincts. AGG, en particulier, compte parmi les actifs à kurtosis la plus extrême du portefeuille (52.9, cf. Section 4.2.3), ce qui suggère que le VAE peine spécifiquement à reproduire les distributions à queues très épaisses. SHY, quant à lui, présente un profil inverse : il s’agit de l’actif à l’écart-type le plus faible du portefeuille (0.111%) et à la plage de variation la plus resserrée (Table 6), ce qui rend le test de Kolmogorov-Smirnov particulièrement sensible à de faibles écarts absolus entre scénarios générés et rendements historiques.

4.4.2 Comparaison au niveau du portefeuille

Le tableau 3 compare les moments statistiques du rendement du portefeuille (poids égaux 1/60) calculé sur les scénarios générés par le VAE et sur les rendements historiques

réels.

Statistique	Généré (VAE)	Historique
Moyenne	0.0159%	0.0263%
Écart-type	0.8494%	0.9605%
Skewness	-0.402	-0.626
Kurtosis (excès)	2.685	13.354
Min	-5.20%	-8.95%
Max	4.80%	8.59%
Sharpe (annualisé)	0.297	0.435

TABLE 3 – Comparaison des moments du rendement du portefeuille : scénarios générés vs historique

Le VAE reproduit correctement l'ordre de grandeur de la volatilité du portefeuille (écart-type de 0.85% contre 0.96% en historique) ainsi que le signe et l'ordre de grandeur de l'asymétrie (skewness négative dans les deux cas). L'écart le plus marquant concerne la kurtosis : 2.69 pour les scénarios générés contre 13.35 pour l'historique, soit un excès de kurtosis presque cinq fois inférieur. Cet écart trouve une explication structurelle dans la littérature récente sur les VAE : Kim et al. (2024), montrent que le prior gaussien standard, utilisé pour régulariser l'espace latent, présente une décroissance trop rapide dans les queues pour représenter fidèlement des structures de données à queues épaisses [8]. Le VAE implémenté dans ce travail, dont le décodeur repose également sur une architecture gaussienne classique, semble donc affecté par cette limite structurelle plutôt que par un simple défaut d'entraînement.

4.5 Résultats VaR et CVaR (Expected Shortfall)

Le tableau 4 présente les résultats de VaR historique, VaR paramétrique (gaussienne) et CVaR, aux niveaux de confiance de 95% et 99%, calculés à la fois sur les scénarios générés par le VAE et sur les rendements historiques réels du portefeuille.

Niveau	Généré (VAE)			Historique		
	VaR Hist.	VaR Param.	CVaR	VaR Hist.	VaR Param.	CVaR
95%	-1.461%	-1.381%	-2.120%	-1.383%	-1.554%	-2.433%
99%	-2.529%	-1.960%	-3.096%	-2.850%	-2.208%	-4.481%

TABLE 4 – VaR historique, VaR paramétrique et CVaR à 95% et 99%, scénarios générés vs historique

À 95%, les écarts entre scénarios générés et rendements historiques restent modérés, quelle que soit la méthode : la VaR historique générée (-1.461%) est même légèrement plus conservatrice que la VaR historique réelle (-1.383%), et l'écart sur la CVaR ne dépasse pas 0.31 point de pourcentage. Ce résultat est cohérent avec l'analyse des moments, qui montrait une bonne reproduction de la volatilité et de l'asymétrie du portefeuille par le VAE.

À 99%, en revanche, l'écart se creuse nettement, en particulier sur la CVaR : -3.096% pour les scénarios générés contre -4.481% pour l'historique, soit une sous-estimation du risque de queue d'environ 1.4 point de pourcentage, cohérente avec l'écart de kurtosis déjà documenté (2.69 contre 13.35). La VaR historique générée à 99% (-2.529%) sous-estime

également la VaR historique réelle (-2.850%), bien que dans une moindre mesure que la CVaR .

On observe par ailleurs que la VaR paramétrique (gaussienne), qu'elle soit appliquée aux scénarios générés ou aux rendements historiques, sous-estime systématiquement le risque par rapport à la VaR historique à 99% (-1.960% et -2.208% respectivement, contre -2.529% et -2.850%). Cela confirme que l'hypothèse de normalité reste inadaptée pour ce portefeuille, indépendamment même de la question du VAE, un argument supplémentaire en faveur d'une approche non paramétrique pour l'estimation du risque de queue.

Ces résultats, obtenus par simple comparaison des quantiles, restent toutefois descriptifs : ils ne permettent pas de conclure formellement sur la fiabilité statistique de la VaR issue du VAE. C'est l'objet du test de backtesting de Kupiec, présenté dans la prochaine section.

4.6 Backtesting de la VaR : test de Kupiec

Afin d'évaluer statistiquement la fiabilité de la VaR issue du VAE, un test de backtesting de Kupiec (test POF : Proportion Of Failure) est appliqué : il compare le nombre de violations observées sur les rendements historiques réels au nombre attendu compte tenu du niveau de confiance, via une statistique du rapport de vraisemblance suivant une loi du χ^2 à un degré de liberté. Deux configurations sont testées : la VaR issue des scénarios générés par le VAE, confrontée aux $n = 4448$ rendements historiques réels (test principal, seul à constituer une validation indépendante) ; et à titre de référence, la VaR historique calculée et testée sur ce même échantillon – un test quasi tautologique puisque la VaR historique est par construction le quantile empirique de cet échantillon.

Méthode	Niveau	Viol.	Taux obs.	Taux att.	LR	p-value	Concl.
Généré (VAE) – VaR Hist.	95%	207	4.654%	5%	1.148	0.284	VaR va
Généré (VAE) – VaR Param.	95%	224	5.036%	5%	0.012	0.912	VaR va
Référence in-sample – VaR Hist.	95%	223	5.014%	5%	0.002	0.967	VaR va
Référence in-sample – VaR Param.	95%	186	4.182%	5%	6.625	0.010	VaR re
Généré (VAE) – VaR Hist.	99%	67	1.506%	1%	9.969	0.0016	VaR re
Généré (VAE) – VaR Param.	99%	113	2.541%	1%	74.742	<0.0001	VaR re
Référence in-sample – VaR Hist.	99%	45	1.012%	1%	0.006	0.938	VaR va
Référence in-sample – VaR Param.	99%	88	1.978%	1%	33.476	<0.0001	VaR re

TABLE 5 – Résultats du test de Kupiec ($n = 4448$ observations historiques, $\alpha = 5\%$)

À 95%, la VaR issue du VAE est validée par le test, quelle que soit la méthode sous-jacente ($p = 0.284$ et $p = 0.912$), confirmant que le modèle reproduit correctement le risque de marché courant du portefeuille. À 99%, elle est en revanche rejetée dans les deux cas ($p = 0.0016$ et $p < 0.0001$) : le VAE sous-estime significativement le risque extrême, cohérent avec l'écart de kurtosis déjà documenté et la limite structurelle des VAE à decodeur gaussien pour représenter les queues épaisses de kim et al. (2024). Les tests de référence in-sample confirment l'analyse méthodologique : la VaR historique in-sample est validée aux deux niveaux, tandis que la VaR paramétrique in-sample est rejetée même sur son propre échantillon, signe que l'hypothèse de normalité reste inadaptée à ce portefeuille, indépendamment du VAE. Le VAE constitue donc un outil fiable pour l'estimation de la VaR à un niveau de confiance courant, mais nécessiterait des aménagements par exemple

un décodeur à queues plus épaisses de type Student pour être utilisé de façon fiable à des niveaux réglementaires plus élevés (99%).

A Annexe : Architecture Neurale de l'Auto-Encodeur Classique

Afin de poser les bases de l'encodage et du décodage par réseaux de neurones, nous détaillons ici l'architecture d'un Auto-Encodeur (AE) classique. Pour respecter les contraintes calculatoires de cette étude, nous utilisons des Perceptrons Multicouches (MLP - *Multi-Layer Perceptrons*).

A.1 Architecture Déterministe (Encodeur et Décodeur)

Soit $x \in \mathbb{R}^d$ le vecteur d'entrée (par exemple, les variables quantitatives d'une observation) et $z \in \mathbb{R}^k$ le vecteur latent compressé, avec $k \ll d$. Les réseaux de neurones sont définis par une succession de transformations linéaires suivies de fonctions d'activation non-linéaires (typiquement ReLU, $f(u) = \max(0, u)$).

L'Encodeur f_ϕ projette l'entrée x de manière purement déterministe vers l'espace latent. En utilisant une couche cachée h_e , la propagation avant (*forward pass*) s'écrit :

$$h_e = \text{ReLU}(W_1 x + b_1) \quad (28)$$

$$z = W_z h_e + b_z \quad (29)$$

Où $\phi = \{W_1, b_1, W_z, b_z\}$ représentent les matrices de poids et les vecteurs de biais à optimiser.

Le Décodeur g_θ prend ce vecteur latent z et tente de reconstruire l'observation initiale x :

$$h_d = \text{ReLU}(W_2 z + b_2) \quad (30)$$

$$\hat{x} = W_{out} h_d + b_{out} \quad (31)$$

Où $\theta = \{W_2, b_2, W_{out}, b_{out}\}$ représentent les paramètres du décodeur.

A.2 Entraînement de bout en bout et Rétropropagation

Contrairement aux modèles variationnels qui optimisent une borne inférieure probabiliste (ELBO), l'Auto-Encodeur classique s'entraîne uniquement en minimisant l'erreur de reconstruction entre l'entrée x et la prédiction $\hat{x}$. Pour des données tabulaires continues, la fonction de perte standard est l'Erreur Quadratique Moyenne (*Mean Squared Error* - MSE) :

$$\mathcal{L}_{AE}(\phi, \theta) = \frac{1}{N} \sum_{i=1}^N \|x_i - \hat{x}_i\|^2 \quad (32)$$

L'aspect fondamental de cette architecture est son apprentissage *de bout en bout* (end-to-end). L'encodeur et le décodeur sont optimisés simultanément sans qu'il soit nécessaire de fournir au modèle une représentation latente z "cible". Cela est rendu possible par l'algorithme de rétropropagation du gradient, fondé sur la règle de dérivation des fonctions composées (*chain rule*).

Lors de la descente de gradient, les paramètres sont mis à jour conjointement :

- **Pour le Décodeur** (θ) : L'erreur étant calculée directement à sa sortie, le gradient $\nabla_\theta \mathcal{L}$ s'obtient par dérivation classique de la perte par rapport à ses propres poids.

- **Pour l'Encodeur** (ϕ) : Le gradient doit remonter à travers le décodeur pour atteindre l'encodeur. La mise à jour s'effectue via le gradient rétropropagé à travers l'espace latent z :

$$\frac{\partial \mathcal{L}_{AE}}{\partial \phi} = \frac{\partial \mathcal{L}_{AE}}{\partial \hat{x}} \times \frac{\partial \hat{x}}{\partial z} \times \frac{\partial z}{\partial \phi} \quad (33)$$

Grâce à cette formulation, l'encodeur ajuste ses poids ϕ en fonction de la manière dont sa compression (z) a impacté la reconstruction finale du décodeur ($\hat{x}$). Une représentation latente pertinente et structurée émerge ainsi naturellement de cette co-optimisation.

B Annexe : Fondements Théoriques de la Divergence KL

Cette section détaille l'origine de la divergence de Kullback-Leibler à partir des concepts fondamentaux de la théorie de l'information.

B.1 L'Information de Shannon (Surprise)

L'information $I(x)$ d'un événement x est définie par sa probabilité d'occurrence $P(x)$. Plus un événement est rare, plus sa réalisation est informative. Pour garantir l'additivité de l'information pour des événements indépendants, Shannon [9] utilise le logarithme :

$$I(x) = \log \left(\frac{1}{P(x)} \right) = -\log P(x) \quad (34)$$

B.2 L'Entropie : L'Incertitude Moyenne

L'entropie $H(P)$ représente la quantité moyenne d'information contenue dans une distribution P . C'est l'espérance de la "surprise" :

$$H(P) = \mathbb{E}_{x \sim P}[I(x)] = - \sum_i P(x_i) \log P(x_i) \quad (35)$$

Elle mesure l'incertitude intrinsèque du système. Un système parfaitement prévisible possède une entropie nulle.

B.3 L'Entropie Croisée

Considérons une "vraie" distribution P et un modèle d'approximation Q . Si nous codons les événements en supposant (à tort) qu'ils suivent Q , alors que la réalité suit P , la surprise moyenne obtenue est l'entropie croisée :

$$H(P, Q) = \mathbb{E}_{x \sim P}[-\log Q(x)] = - \sum_i P(x_i) \log Q(x_i) \quad (36)$$

B.4 Dérivation de la Divergence KL

La divergence de Kullback-Leibler correspond au **surplus d'information** (ou inefficacité) induit par l'utilisation de Q au lieu de P . Elle se définit comme la différence entre l'entropie croisée et l'entropie réelle :

$$D_{KL}(P \parallel Q) = H(P, Q) - H(P) \quad (37)$$

Par substitution des définitions précédentes :

$$D_{KL}(P \parallel Q) = \left(- \sum P(x_i) \log Q(x_i) \right) - \left(- \sum P(x_i) \log P(x_i) \right) \quad (38)$$

$$= \sum P(x_i) [\log P(x_i) - \log Q(x_i)] \quad (39)$$

$$= \sum_i P(x_i) \log \left(\frac{P(x_i)}{Q(x_i)} \right) \quad (40)$$

C Annexe : De la projection ponctuelle à la zone de probabilité

Comme illustré par la Figure 2, la transition vers le cadre variationnel impose un changement radical dans la manière dont l'espace latent est investi.

C.1 Le paradigme de la « tâche de couleur »

Alors qu'un Auto-Encodeur classique projette une donnée x sur une coordonnée discrète z (comparable à un pixel noir sur une feuille blanche), l'encodeur du VAE projette x sous forme d'une **distribution de probabilité**. On peut visualiser cela comme une « tâche de couleur » étalée sur l'espace latent.

- **L'enveloppe de probabilité** : L'encodeur ne prédit pas une position, mais les paramètres d'une zone : le centre $\mu(x)$ (moyenne) et le rayon $\sigma(x)$ (écart-type).
- **L'échantillonnage** : Le décodeur ne reçoit jamais deux fois exactement le même point pour une même donnée d'entrée. Il apprend à reconstruire à partir de n'importe quel échantillon z tiré à l'intérieur de cette zone via le *reparameterization trick* : $z = \mu(x) + \sigma(x) \odot \epsilon$.

C.2 Mécanisme de densification via la KL Divergence

Sans contrainte de régularisation, l'encodeur aurait tendance à placer ces « tâches » le plus loin possible les unes des autres pour éviter toute confusion lors de la reconstruction, recréant ainsi les discontinuités de l'AE classique.

La divergence de Kullback-Leibler agit ici comme un **élastique mathématique** rattaché à l'origine $(0, 0)$ de l'espace latent. Elle force l'encodeur à respecter deux consignes de « bon voisinage » :

1. **Le centrage** ($\mu \rightarrow 0$) : Toutes les zones de probabilité sont poussées vers le centre du Prior $\mathcal{N}(0, I)$.
2. **L'expansion contrôlée** ($\sigma \rightarrow 1$) : Chaque zone doit conserver une largeur suffisante pour se superposer partiellement à ses voisines.

C.3 La continuité par le chevauchement

C'est ce **chevauchement forcé** qui crée la continuité de l'espace latent. Entre deux zones connues (par exemple un visage neutre et un visage souriant), il n'existe plus de « vide » informationnel. Le décodeur, habitué à traiter des incertitudes, est capable d'interpréter les points situés à l'intersection de deux distributions comme des mélanges cohérents (un visage esquissant un début de sourire).

Synthèse conceptuelle

La projection variationnelle transforme l'espace latent d'un simple **dictionnaire de points** en un **atlas continu de probabilités**. La KL divergence garantit que cet atlas reste compact, évitant ainsi les zones de « no man's land » mathématique où le décodeur produirait des reconstructions aberrantes.

D Annexe : Intuition et Dynamique de l'ELBO

La décomposition mathématique de l'ELBO peut être interprétée comme un système physique en équilibre. Cette annexe vise à éclairer la mécanique interne du VAE au-delà du formalisme bayésien.

D.1 Le principe du « plancher mobile »

Mathématiquement, nous ne pouvons pas mesurer directement la « hauteur » de la log-vraisemblance $\log p_\theta(x)$. Cependant, l'inégalité démontrée en Section 2 montre que l'ELBO est une borne inférieure systématique.

En maximisant l'ELBO via la descente de gradient, nous « poussons » ce plancher vers le haut. Comme l'écart entre le plancher et le plafond est défini par la divergence KL entre notre encodeur et le vrai *posteriori*, soulever le plancher réduit mécaniquement cet écart et améliore la qualité du modèle.

D.2 La négociation entre fidélité et régularité

L'ELBO impose une co-adaptation entre les deux réseaux de neurones :

- **Le Décodeur (Fidélité)** : Il cherche à minimiser l'erreur de reconstruction. Il pousse l'encodeur à créer des représentations latentes z très distinctes pour chaque donnée afin d'éviter toute confusion.
- **Le Prior (Régularité)** : Le terme de divergence KL force l'encodeur à ne pas trop s'étaler et à rester proche de la loi $\mathcal{N}(0, I)$.

D.3 L'Inférence Variationnelle comme apprentissage

Il est fondamental de noter que q_ϕ et p_θ sont des réseaux de neurones. L'encodeur q_ϕ n'est pas « intrinsèquement » bayésien ; il est un approximateur universel qui apprend à prédire les paramètres μ et σ d'une distribution. Sa force réside dans sa capacité à apprendre une fonction de mapping complexe entre un espace de données brut (pixels, signaux) et une structure latente organisée, là où un calcul exact de Bayes échouerait par intraitabilité.

Synthèse

Maximiser l'ELBO, c'est forcer un réseau de neurones à trouver une manière de compresser le monde sans perdre son essence, tout en respectant une règle de simplicité imposée par le Prior.

E Annexe : Détails d'implémentation

E.1 Statistiques descriptives complètes des 60 actifs

TABLE 6: Statistiques descriptives détaillées des rendements journaliers, 60 actifs (novembre 2004 – juin 2026)

Ticker	Moyenne	Écart-type	Skewness	Kurtosis	Min	Max
AGG	-0.0008%	0.374%	-1.359	52.90	-6.85%	5.88%
CL=F	0.0278%	3.028%	2.126	60.64	-28.22%	64.63%
DIA	0.0365%	1.236%	-0.526	15.82	-13.65%	11.19%
DX-Y.NYB	0.0036%	0.526%	0.018	3.34	-3.68%	3.62%
EEM	0.0271%	1.870%	-0.260	10.79	-17.63%	15.78%
EFA	0.0168%	1.464%	-0.535	11.51	-11.84%	13.15%
ES=F	0.0429%	1.313%	-0.420	12.57	-10.96%	11.77%
EWA	0.0147%	1.874%	-0.500	11.04	-17.56%	14.03%
EWC	0.0291%	1.544%	-0.628	13.11	-14.30%	13.82%
EWG	0.0212%	1.712%	-0.451	8.87	-13.57%	15.05%
EWH	0.0161%	1.629%	-0.079	8.19	-13.12%	13.35%
EWJ	0.0186%	1.396%	-0.303	8.67	-10.99%	14.15%
EWQ	0.0162%	1.721%	-0.512	9.58	-13.57%	14.58%
EWS	0.0170%	1.592%	0.261	15.89	-11.83%	22.55%
EWU	0.0076%	1.568%	-0.675	13.70	-12.81%	16.92%
EWV	0.0290%	1.935%	-0.317	9.71	-16.55%	17.80%
FXI	0.0153%	2.227%	0.066	7.70	-16.07%	19.26%
GC=F	0.0526%	1.265%	-0.505	6.78	-12.07%	8.64%
GLD	0.0504%	1.251%	-0.396	6.24	-10.84%	10.70%
HG=F	0.0337%	1.946%	-0.495	11.08	-25.17%	14.83%
IEF	0.0021%	0.477%	-0.067	4.01	-3.07%	3.69%
IVV	0.0428%	1.293%	-0.544	11.29	-12.30%	10.41%
IWM	0.0355%	1.654%	-0.449	6.75	-14.23%	12.48%
IYR	0.0137%	1.852%	-0.809	20.36	-23.08%	18.28%
KC=F	0.0259%	2.287%	0.283	3.50	-11.09%	22.67%
LQD	-0.0004%	0.607%	-0.908	57.62	-9.55%	9.32%
NG=F	-0.0174%	4.122%	-0.334	20.20	-64.40%	43.55%
NQ=F	0.0674%	1.484%	-0.330	7.11	-11.48%	11.21%
QQQ	0.0671%	1.479%	-0.307	6.74	-12.76%	11.34%
SHY	0.0002%	0.111%	-0.395	7.30	-0.74%	0.99%
SPY	0.0427%	1.301%	-0.437	12.90	-11.59%	12.07%
TIP	0.0011%	0.447%	-0.225	19.51	-5.20%	6.22%
TLT	-0.0013%	1.028%	-0.073	7.75	-9.01%	11.29%
VOX	0.0301%	1.438%	-0.124	9.19	-12.13%	13.25%
VTI	0.0430%	1.322%	-0.498	11.58	-12.08%	11.21%
XLB	0.0294%	1.624%	-0.274	8.94	-13.25%	15.89%
XLE	0.0268%	2.086%	-0.675	12.34	-22.49%	16.38%
XLF	0.0182%	1.973%	0.202	22.18	-18.23%	26.26%
XLI	0.0400%	1.450%	-0.417	9.90	-12.04%	11.91%

suite à la page suivante

Table 6 – suite

Ticker	Moyenne	Écart-type	Skewness	Kurtosis	Min	Max
XLK	0.0662%	1.521%	-0.277	8.20	-14.87%	12.60%
XLP	0.0299%	0.972%	-0.690	11.45	-10.27%	8.17%
XLU	0.0277%	1.289%	-0.630	14.80	-14.50%	12.04%
XLV	0.0379%	1.158%	-0.530	14.43	-12.48%	13.39%
XLY	0.0450%	1.519%	-0.363	8.43	-13.55%	11.35%
ZC=F	0.0185%	2.018%	-0.763	10.50	-25.20%	12.76%
ZW=F	0.0142%	2.270%	0.298	3.00	-11.30%	19.70%
^AEX	0.0254%	1.361%	-0.403	9.55	-11.38%	9.78%
^AXJO	0.0194%	1.150%	-0.592	9.34	-10.26%	9.03%
^BSES	0.0573%	1.451%	-0.143	10.62	-12.80%	15.99%
^DJI	0.0366%	1.233%	-0.595	14.57	-13.84%	10.76%
^FCHI	0.0178%	1.454%	-0.184	9.24	-13.10%	13.30%
^FTSE	0.0180%	1.212%	-0.301	12.29	-11.51%	11.11%
^GDAXI	0.0411%	1.438%	-0.183	8.96	-13.05%	13.46%
^GSPC	0.0429%	1.307%	-0.545	12.15	-12.77%	10.42%
^HSI	0.0141%	1.628%	0.039	11.46	-14.70%	16.80%
^IXIC	0.0584%	1.483%	-0.370	7.52	-13.15%	11.70%
^N225	0.0409%	1.615%	-0.748	12.08	-17.53%	13.67%
^SSMI	0.0197%	1.179%	-0.393	17.58	-12.74%	15.76%
^TNX	0.0048%	2.892%	0.544	41.56	-38.16%	49.67%
^TYX	0.0029%	2.075%	0.109	36.14	-25.98%	33.36%

E.2 Evolution des prix




FIGURE 5 – Évolution des indices boursiers normalisés (base 100, novembre 2004 – juin 2026)

Références

- [1] Kingma, D. P., & Welling, M. (2013). *Auto-encoding variational bayes*. arXiv preprint arXiv :1312.6114.
- [2] Blei, D. M., Kucukelbir, A., & McAuliffe, J. D. (2017). *Variational inference : A review for statisticians*. Journal of the American statistical Association, 112(518), 859-877.
- [3] Kullback, S., & Leibler, R. A. (1951). *On information and sufficiency*. The annals of mathematical statistics, 22(1), 79-86.
- [4] Hull, J.C. (2012). *Risk Management and Financial Institutions* (3^e éd.). Wiley.
- [5] Artzner, P., Delbaen, F., Eber, J-M., & Heath, D. (1999). Coherent measures of risk. *Mathematical Finance*, 9(3), 203–228.
- [6] Arian, H., Moghimi, M., Tabatabaei, E., & Zamani, S. (2020). Encoded Value-at-Risk : A Predictive Machine for Financial Risk Management. *arXiv preprint arXiv :2011.06742*.

- [7] Chicheportiche, R., & Bouchaud, J.-P. (2012). Weighted Kolmogorov-Smirnov test : Accounting for the tails. *Physical Review E—Statistical, Nonlinear, and Soft Matter Physics*, 86(4), 041115.
- [8] Kim, J., Kwon, J., Cho, M., Lee, H., & Won, J.-H. (2024). t^3 -Variational Autoencoder : Learning Heavy-tailed Data with Student's t and Power Divergence. In *International Conference on Learning Representations*, vol. 2024, pp. 19580–19606.
- [9] Shannon, C. E. (1948). *A mathematical theory of communication*. The Bell system technical journal, 27(3), 379-423.